KERNEL SVM

- Nguyễn Hoàng Yến Như
- Nguyễn Trần Phúc Nghi
- Nguyễn Trần Phúc An
- Nguyễn Đức Anh Phúc
- Trịnh Thị Thanh Trúc
- KS. Cao Bá Kiệt
- KS. Quan Chí Khánh An
- KS. Lê Ngọc Huy
- CN. Bùi Cao Doanh
- CN. Nguyễn Trọng Thuận
- KS. Phan Vĩnh Long
- KS. Nguyễn Cường Phát
- ThS. Nguyễn Hoàng Ngân
- KS. Hồ Thái Ngọc
- ThS. Đỗ Văn Tiến
- ThS. Nguyễn Hoàn Mỹ
- ThS. Dương Phi Long
- ThS. Trương Quốc Dũng
- ThS. Nguyễn Thành Hiệp
- ThS. Nguyễn Võ Đăng Khoa
- ThS. Võ Duy Nguyên
- TS. Nguyễn Văn Tâm
- ThS. Trần Việt Thu Phương
- TS. Nguyễn Tấn Trần Minh Khang

DATASET

Dataset

- Tên tập dữ liệu: Social Network Ads.
- Nguồn: https://www.superdatascience.com/pages/machine-learning.
- Tập dữ liệu cho biết các thông tin của khách hàng và họ có mua hàng hay không.

Dataset

- Tập dữ liệu chứa 400 điểm dữ liệu, mỗi điểm dữ liệu có 5 thuộc tính gồm:
  + UserID: Mã số định danh của người dùng.
  + Gender: Giới tính của người dùng.
  + Age: Độ tuổi người dùng.
  + Estimated Salary: Mức lương ước đoán của người dùng.
  + Purchased: Là một trong hai số 0 và 1. Số 0 cho biết khách hàng không mua hàng và số 1 cho biết khách hàng có mua hàng.

Dataset

– Dưới đây là 5 điểm dữ liệu ngẫu nhiên trong tập dữ liệu.

UserID	Gender	Age	Estimated Salary	Purchased
15624510	Male	19	19,000	0
15810944	Male	35	20,000	1
15668575	Female	26	43,000	0
15603246	Female	27	57,000	0
15804002	Male	19	76,000	1

Dataset

– Yêu cầu với 2 thuộc tính:

+ Độ tuổi (Age)

+ Mức lương ước đoán (Estimated Salary)

Dự đoán khách hàng sẽ mua hàng hay không?

TIỀN XỬ LÝ DỮ LIỆU

Tiền xử lý dữ liệu

– Ở bài này, ta chỉ quan tâm đến hai thuộc tính tuổi và mức lương ước đoán.

```
1. import pandas as pd
2. import numpy as np
3. dataset = pd.read_csv("Social_Network_Ads.csv")
4. X = dataset.iloc[:, [2, 3]].values
5. Y = dataset.iloc[:, 4].values
```

Tiền xử lý dữ liệu

- Với mục đích:
  + Thuận tiện cho trực quan hóa kết quả sau khi huấn luyện.
  + Tăng hiệu quả khi huấn luyện trên mô hình SVM.

Ta chuẩn hóa dữ liệu về dạng có kỳ vọng bằng 0 và phương sai bằng 1.

- Lớp `StandardScaler` trong module `sklearn.preprocessing` đã được xây dựng sẵn để chuẩn hóa dữ liệu.

```
7. from sklearn.preprocessing import StandardScaler
8. SC = StandardScaler()
9. X = SC.fit_transform(X)
```

Tiền xử lý dữ liệu

- Chia dữ liệu thành hai tập training set và test set.
- Ta dùng hàm `train_test_split` được cung cấp trong module `sklearn.model_selection`.

```
10.from sklearn.model_selection import train_test_split
11.X_train, X_test, Y_train, Y_test =

train_test_split(X, Y, train_size = 0.8, random_state =
 0)
```

TRỰC QUAN HÓA DỮ LIỆU

Trực quan hóa dữ liệu

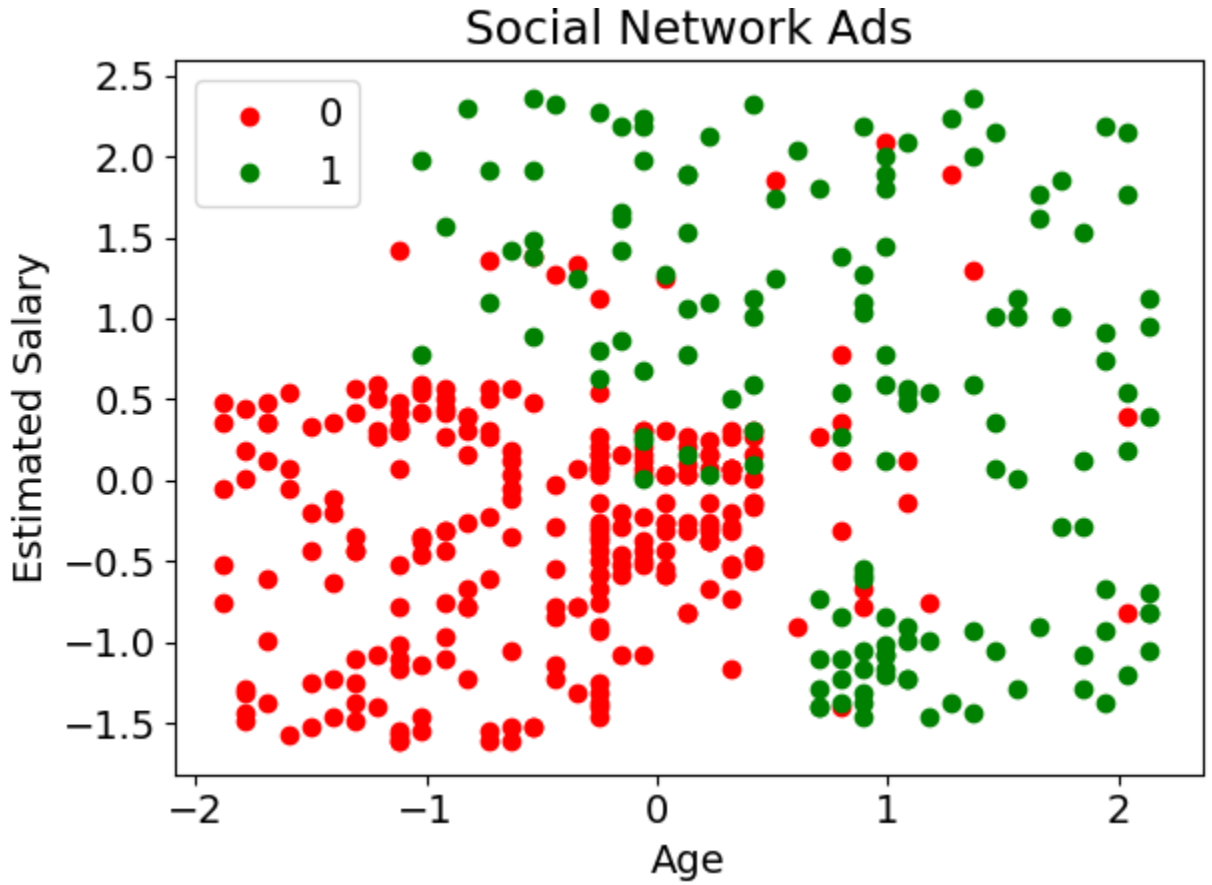

Trực quan hóa dữ liệu

– Xây dựng hàm trực quan hóa các điểm dữ liệu.

```
11.from matplotlib.colors import ListedColormap
12.import matplotlib.pyplot as plt
13.def VisualizingDataset(X_, Y_):
14.    X1 = X_[:, 0]
15.    X2 = X_[:, 1]
16.    for i, label in enumerate(np.unique(Y_)):
17.        plt.scatter(X1[Y_ == label], X2[Y_ == label]
    ,
```

Trực quan hóa dữ liệu

– Gọi hàm trực quan hóa dữ liệu.

```
18.VisualizingDataset(X, Y)
19.plt.show()
```

Trực quan hóa dữ liệu

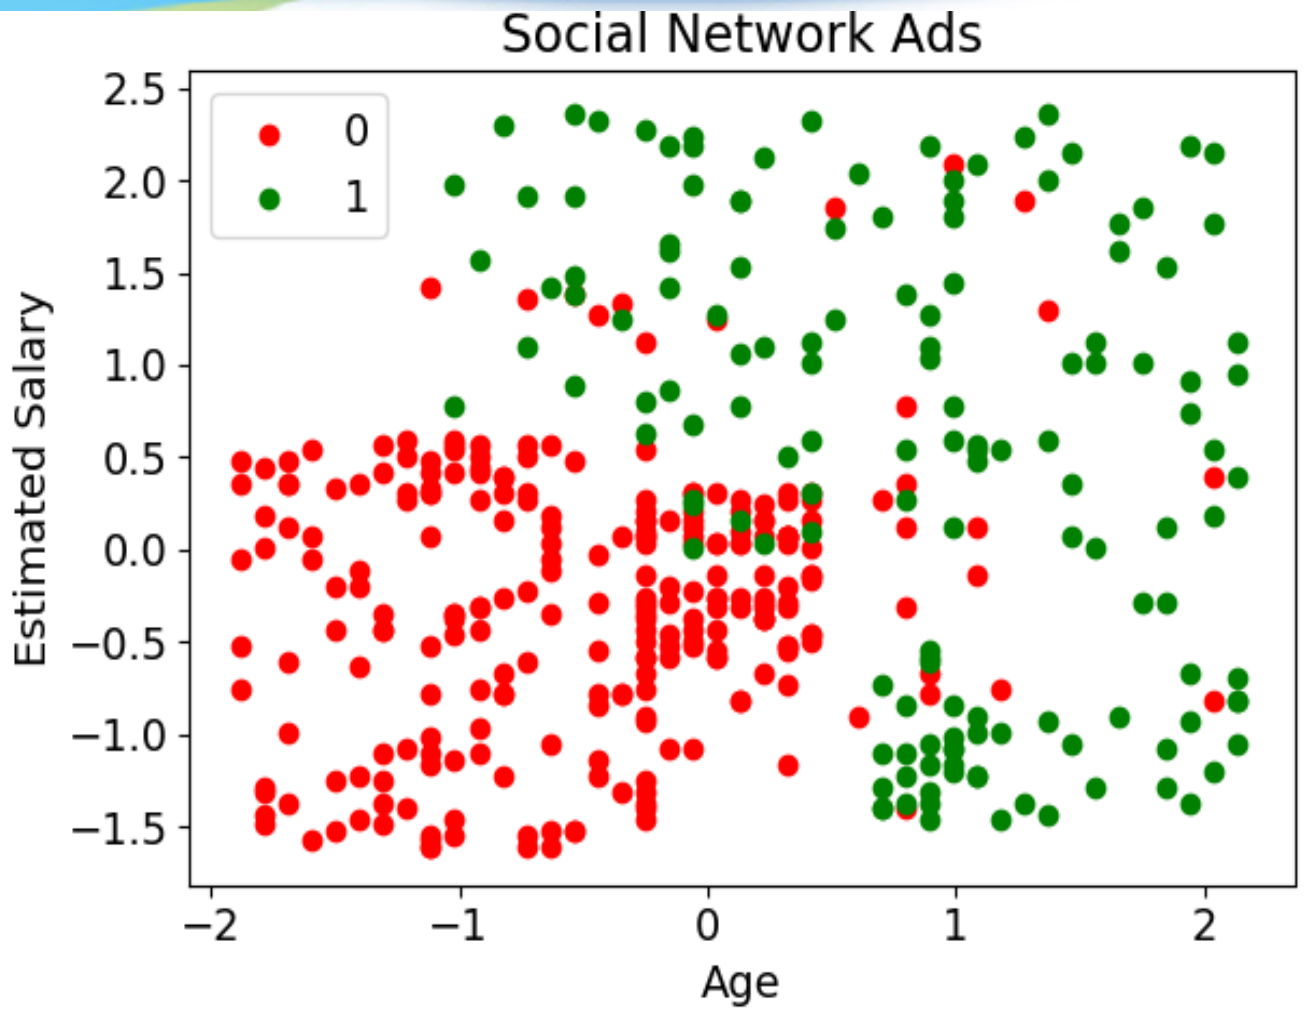

- Theo hình vẽ, ta thấy các điểm có sự phân bố thành 2 mảng.
  - + Mảng dưới trái phần lớn có màu đỏ, tức khách hàng không mua hàng.
  - + Mảng bên phải và mảng bên trên phần lớn có màu xanh, tức khách hàng có mua hàng.

Trực quan hóa dữ liệu

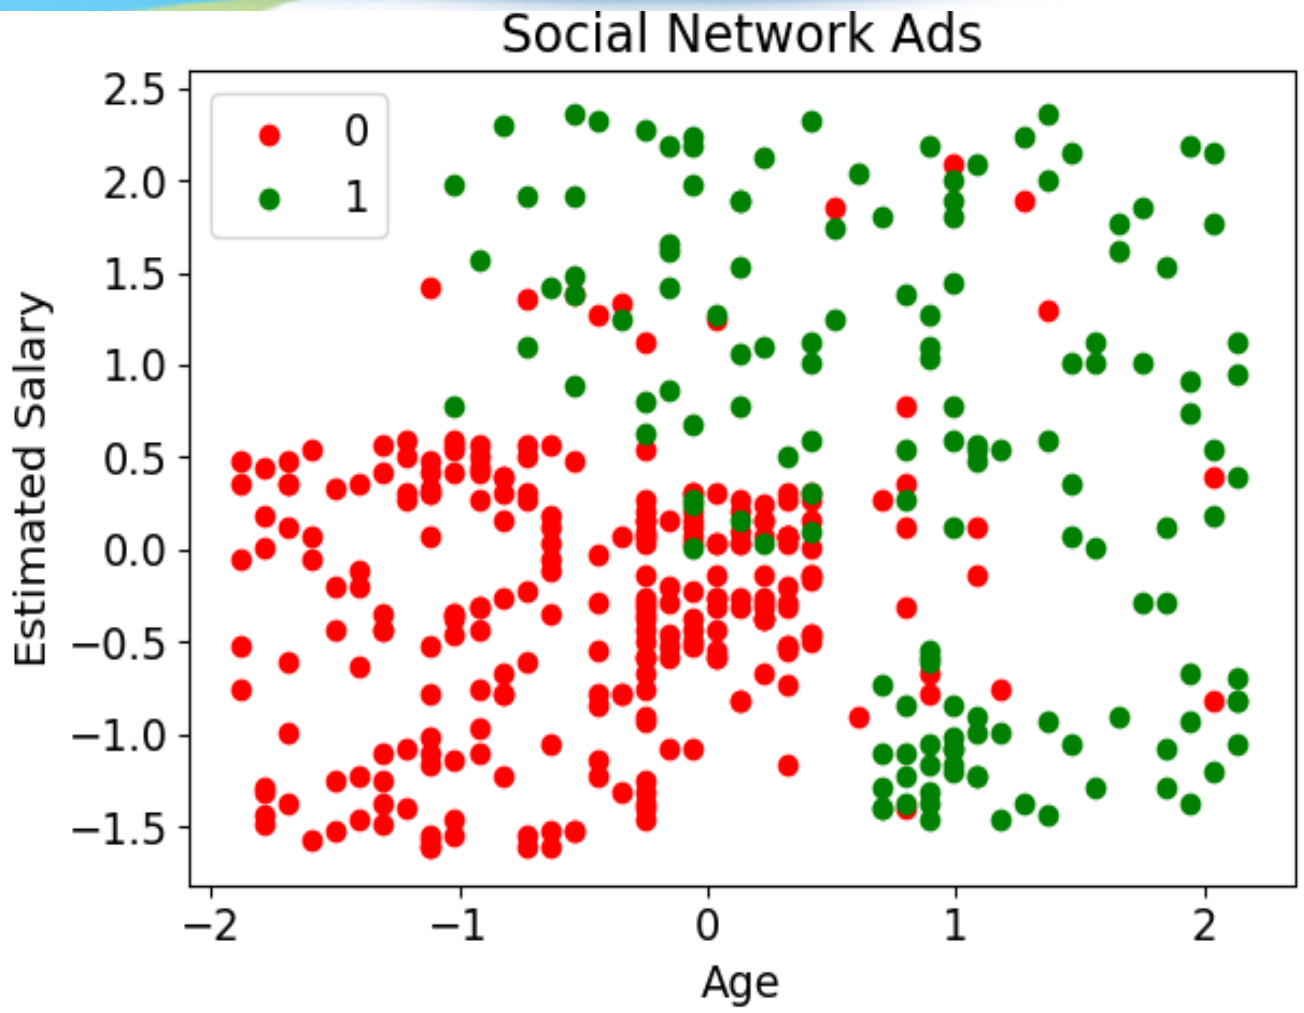

- Điều này là phù hợp vì các khách hàng trẻ và có mức lương thấp sẽ thường không mua hàng.
- Ngược lại, khách hàng cao tuổi hoặc có lương cao sẽ thường mua hàng nhiều hơn.

KERNEL SVM

Kernel SVM

– *Support Vector Machine* là một thuật toán phân loại tuyến tính, do đó, với các dữ liệu không phân biệt tuyến tính, tức đường phân chia không phải là một đường thẳng, *SVM* cho kết quả rất tệ.

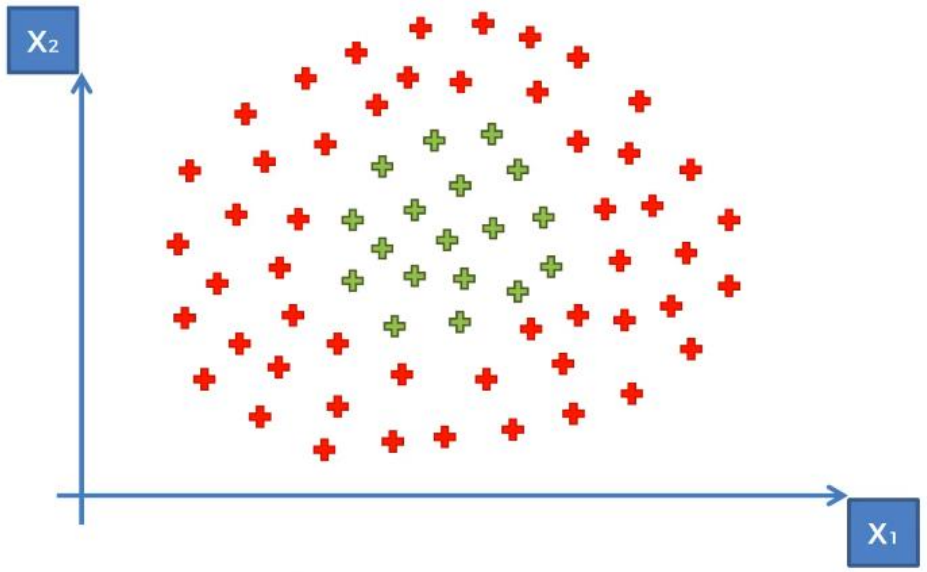

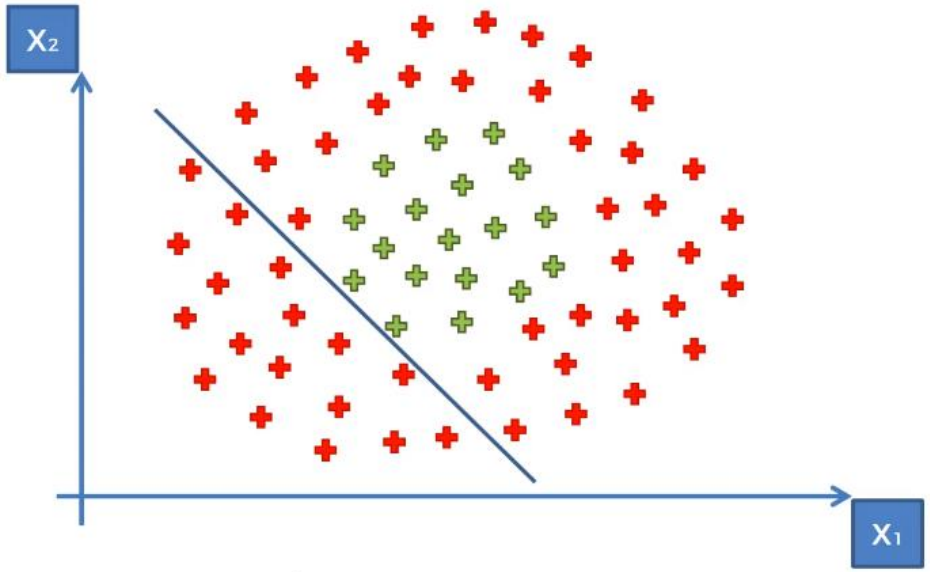

Kernel SVM

- *Kernel SVM* sinh ra để có thể hoạt động tốt trên cả những tập dữ liệu không phân biệt tuyến tính.
- Ý tưởng của *Kernel SVM* là ánh xạ các điểm dữ liệu trong tập dữ liệu hiện tại sang một không gian mới có số chiều lớn hơn.
- Từ đó, dữ liệu không phân biệt tuyến tính sẽ có thể chuyển sang phân biệt tuyến tính.

Kernel SVM

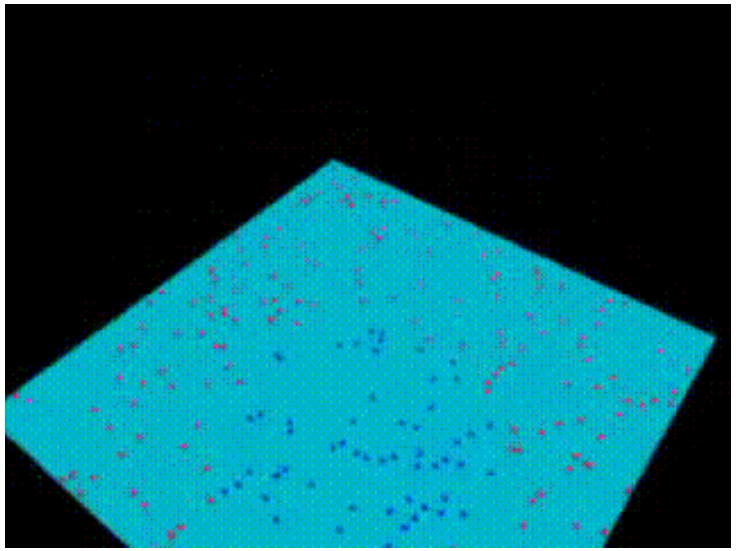

Kernel SVM

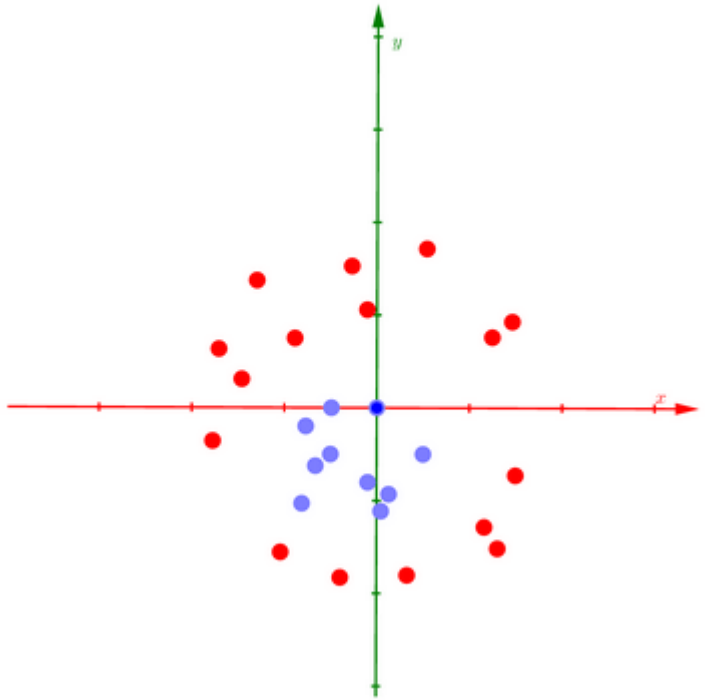

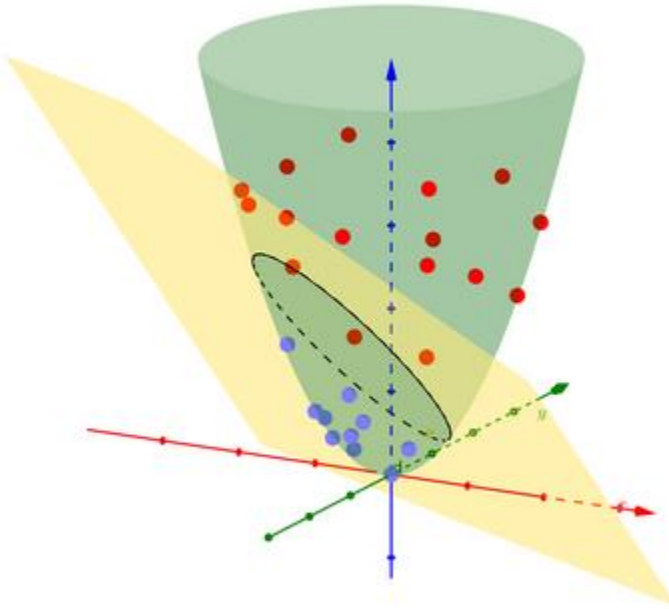

Kernel SVM

- Dưới đây là một cách chuyển dữ liệu không phân biệt tuyến tính ở không gian hai chiều sang không gian ba chiều.
- Ta thêm một chiều z vào hai chiều hiện tại (gọi là x, y), mà ở đó $z = x^2 + y^2$. Khi đó điểm dữ liệu mới sẽ có dạng $[x, y, z]$ hay $[x, y, x^2 + y^2]$.
- Lưu ý, đây chỉ là một trong vô số cách chuyển đổi.

Kernel SVM

- Trong thực tế, số chiều của dữ liệu là rất lớn, có thể lên tới hàng trăm đến hàng triệu chiều.
- Do đó, việc tìm ra được một cách chuyển dữ liệu vào một chiều không gian mới có số chiều cao hơn sẽ tốn rất nhiều thời gian và bộ nhớ.

Kernel SVM

- Cách mà *SVM* dự đoán điểm dữ liệu mới là:
  - + Sau quá trình huấn luyện, mô hình *SVM* sẽ thu được một số (rất ít) vector để phục vụ việc dự đoán sau này (các vector này còn được gọi là support vectors).
  - + Để dự đoán một điểm dữ liệu mới, một công việc mà *SVM* sẽ làm là tính một số giá trị tích vô hướng dựa trên các support vectors.

Kernel SVM

- Trong *SVM*, thay vì phải tìm một công thức chuyển từng điểm dữ liệu vào không gian mới, ta chỉ cần tìm một công thức để tính tích vô hướng của hai vector bất kỳ trong không gian mới mà thôi.
- Việc áp dụng công thức tính tích vô hướng của hai vector trong không gian mới vào *SVM* được gọi là kernel trick. Các công thức tính tích vô hướng này được gọi là các hàm kernel.
- SVM sử dụng kernel trick được gọi là *Kernel SVM*.

Kernel SVM

– Ví dụ:

+ Giả sử tập dữ liệu có các điểm dữ liệu ở không gian 2 chiều

$$\mathbf{x} = [x_1; x_2]^T$$

+ Xét một phép biến đổi từ $\mathbf{x}$ thành một điểm trong không gian 3 chiều

$$\boldsymbol{\phi}(\mathbf{x}) = \left[x_1^2;\ x_2^2;\ x_1 x_2 \sqrt{2}\right]^T$$

Kernel SVM

– Ví dụ:

+ Tính tích vô hướng $\boldsymbol{\phi}(\mathbf{x})^T\boldsymbol{\phi}(\mathbf{z})$ với $\mathbf{x}, \mathbf{z}$ là 2 vector trong không gian ban đầu.

- $\boldsymbol{\phi}(\mathbf{x})^T\boldsymbol{\phi}(\boldsymbol{z}) = \left[x_1^2;\ x_2^2;\ x_1x_2\sqrt{2}\right]^T [z_1^2;\ z_2^2;\ z_1z_2\sqrt{2}]$
- $\boldsymbol{\phi}(\mathbf{x})^T\boldsymbol{\phi}(\boldsymbol{z}) = x_1^2z_1^2 + x_2^2z_2^2 + 2x_1z_1x_2z_2$
- $\boldsymbol{\phi}(\mathbf{x})^T\boldsymbol{\phi}(\boldsymbol{z}) = (x_1z_1 + x_2z_2)^2 = (\mathbf{x}^T\mathbf{z})^2 = \boldsymbol{k}(\mathbf{x}, \mathbf{z})$

+ Ta có thể tính tích vô hướng của 2 vector trong không gian mới mà không cần phải biến đổi 2 vector đó.

Kernel SVM

- Việc tự tạo các hàm kernel trong *SVM* khá khó khăn do phải thỏa mãn một số điều kiện nhất định.
- Một số hàm kernel thông dụng trong *SVM*:
  + Linear: Là kernel đại diện cho *SVM* chuẩn.
  + Radian Basic Function: Là kernel phổ biến nhất sử dụng cho *SVM*.
  + Ngoài ra còn có các kernel sau: Sigmoid, Polynomial,…

HUẤN LUYỆN MÔ HÌNH

Huấn luyện mô hình

- Sử dụng lớp `SVC` trong module `sklearn.svm` để huấn luyện mô hình.
- Ta sẽ sử dụng kernel Radian Basic Function cho Kernel SVM. Kernel này được thiết lập với tham số `kernel = "rbf"`.

```
20.from sklearn.svm import SVC
21.classifier = SVC(kernel = “rbf")
22.classifier.fit(X_train, Y_train)
```

TRỰC QUAN HÓA KẾT QUẢ MÔ HÌNH

Trực quan hóa kết quả mô hình

- Ta tạo một *confusion matrix*. Đây là một ma trận có kích thước là $p \times p$ với p là số phân lớp trong bài toán đang xét, ở đây là 2.
- Phần tử ở dòng thứ i, cột thứ j của confusion matrix biểu thị số lượng phần tử có loại là i và được phân vào loại j.
- Hàm `confusion_matrix` trong module `sklearn.metrics` sẽ hỗ trợ ta xây dựng confusion matrix.

```
23.from sklearn.metrics import confusion_matrix
24.cm = confusion_matrix(Y_train, classifier.predict(X_
   train))
25.print(cm)
```

Trực quan hóa kết quả mô hình

- Confusion Matrix được in ra là:

	0	1
0	178	21
1	10	111

- Theo ma trận trên, số lượng dữ liệu được phân loại đúng là $178 + 111 = 299$ điểm dữ liệu.
- Số lượng dữ liệu phân loại sai là $21 + 10 = 31$ điểm dữ liệu.
- Tỉ lệ điểm dữ liệu phân loại sai là $26/320 \approx 0.097$.

Trực quan hóa kết quả mô hình

- Ta trực quan hóa kết quả mô hình trên mặt phẳng tọa độ bằng cách vẽ 2 vùng phân chia mà mô hình thu được sau quá trình huấn luyện.

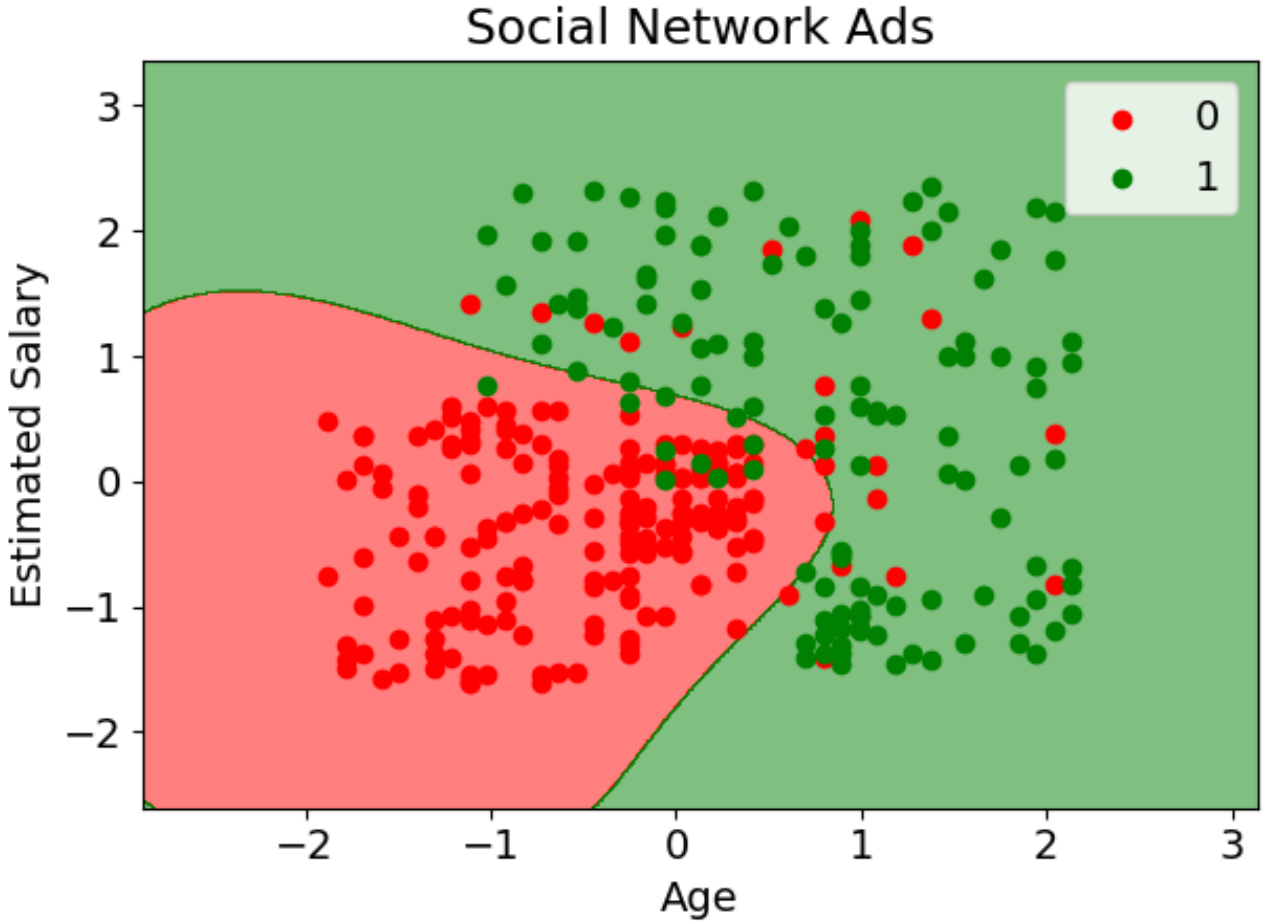

Trực quan hóa kết quả mô hình

– Xây dựng hàm trực quan hóa kết quả bằng cách tạo 2 vùng phân chia mà mô hình đạt được.

```
26. def VisualizingResult(model, X_):
27.     X1 = X_[:, 0]
28.     X2 = X_[:, 1]
29.     X1_range = np.arange(start= X1.min()-1, stop= X1.max()+1, step =
    0.01)
30.     X2_range = np.arange(start= X2.min()-1, stop= X2.max()+1, step =
    0.01)
31.     X1_matrix, X2_matrix = np.meshgrid(X1_range, X2_range)
```

Trực quan hóa kết quả mô hình

– Xây dựng hàm trực quan hóa kết quả bằng cách tạo 2 vùng phân chia mà mô hình đạt được.

```
26.def VisualizingResult(model, X_):
31.     ...
32.     X_grid= np.array([X1_matrix.ravel(),
   X2_matrix.ravel()]).T
33.     Y_grid=
   model.predict(X_grid).reshape(X1_matrix.shape)
34.     plt.contourf(X1_matrix, X2_matrix, Y_grid, alpha
   = 0.5,    cmap = ListedColormap(("red", "green")))
```

Trực quan hóa kết quả mô hình

– Trực quan hóa kết quả mô hình.

```
35.VisualizingResult(classifier, X_train)
36.plt.show()
```

Trực quan hóa kết quả mô hình

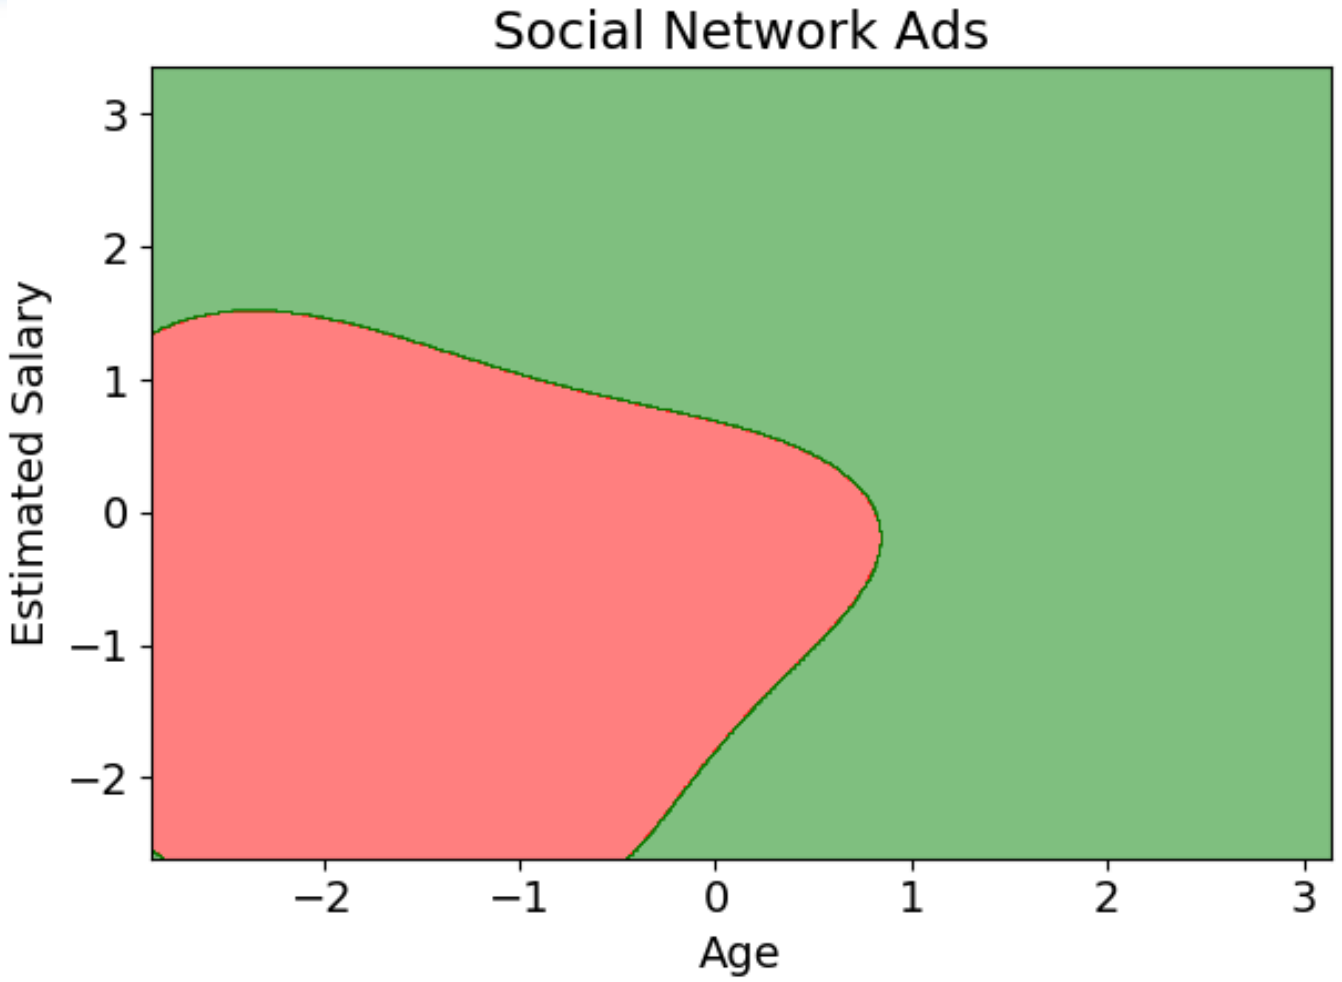

Trực quan hóa kết quả mô hình

- Hoàn thiện quá trình trực quan bằng cách vẽ thêm các điểm dữ liệu huấn luyện lên mặt phẳng tọa độ.

```
37.VisualizingResult(classifier, X_train)
38.VisualizingDataset(X_train, Y_train)
39.plt.show()
```

Trực quan hóa kết quả mô hình

– Mô hình có độ chính xác khá cao.

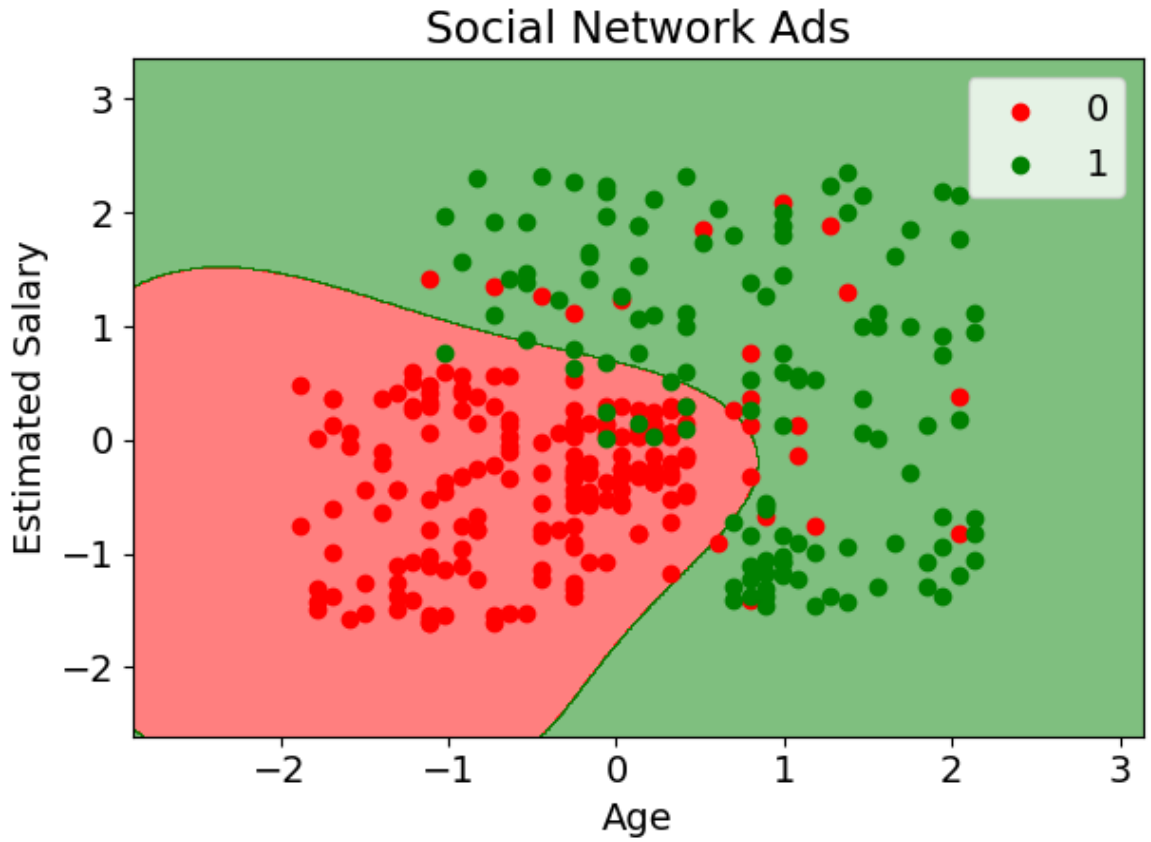

Trực quan hóa kết quả mô hình

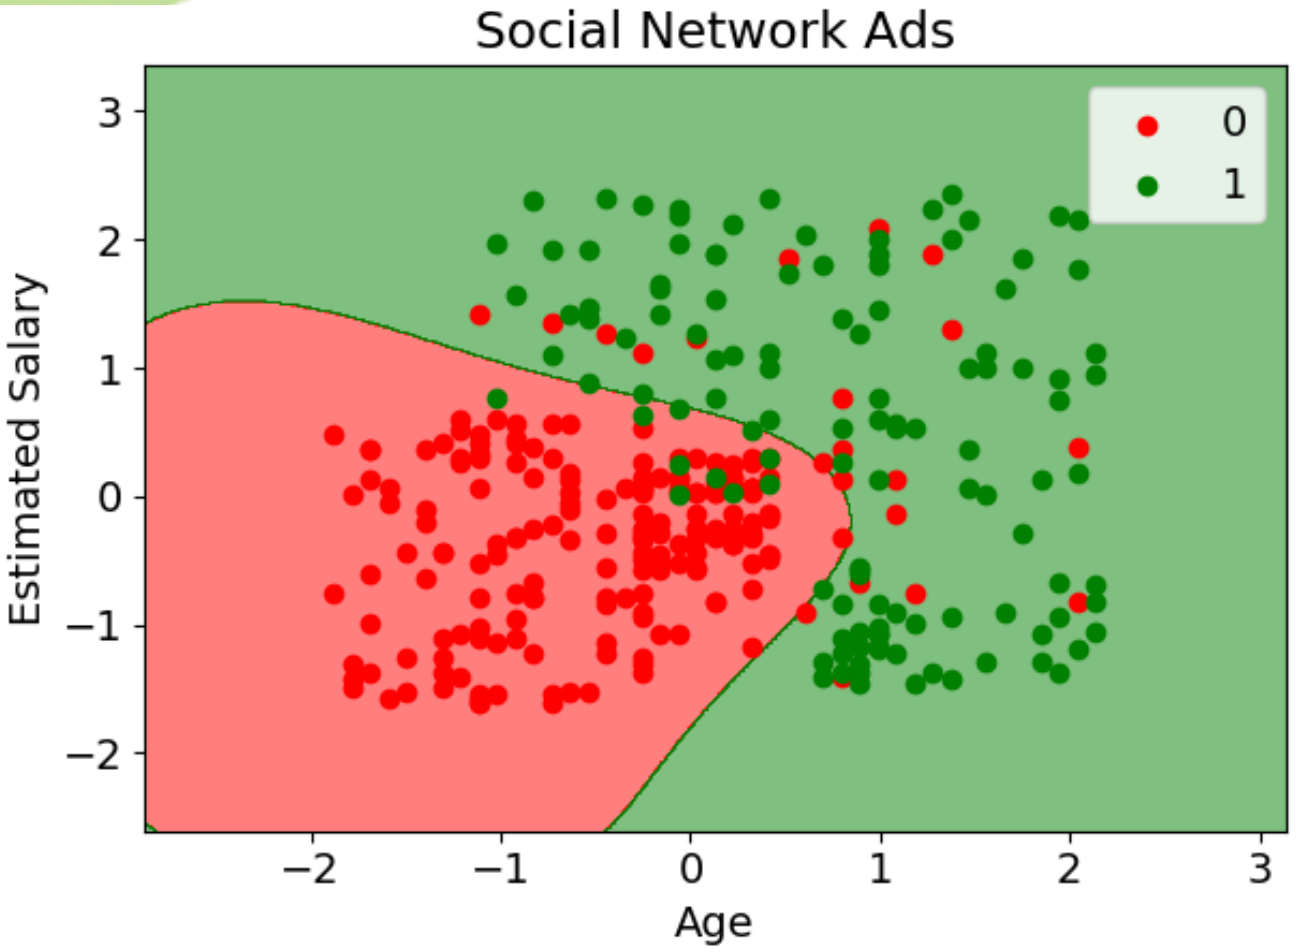

- Nhận xét:
  - + Mô hình có phân chia khá chính xác.
  - + Đường phân chia rõ ràng, phù hợp với các nhận xét về bộ dữ liệu.

KIỂM TRA KẾT QUẢ TRÊN TẬP TEST

Kiểm tra kết quả trên tập test

– Tạo *confusion matrix* trên tập test.

```
40.cm = confusion_matrix(Y_test, classifier.predict(X_t
   est))
41.print(cm)
```

Kiểm tra kết quả trên tập test

– Confusion Matrix được in ra là:

	0	1
0	55	3
1	1	21

– Theo ma trận trên, số lượng dữ liệu được phân loại đúng là $55 + 21 = 76$ điểm dữ liệu.

– Số lượng dữ liệu phân loại sai là $1 + 3 = 4$ điểm dữ liệu.

– Tỉ lệ điểm dữ liệu phân loại sai là $4/80 \approx 0.05$.

Kiểm tra kết quả trên tập test

– Thực hiện tương tự trực quan hóa kết quả mô hình trên tập traning.

```
42.VisualizingResult(classifier, X_test)
43.VisualizingDataset(X_test, Y_test)
44.plt.show()
```

Kiểm tra kết quả trên tập test

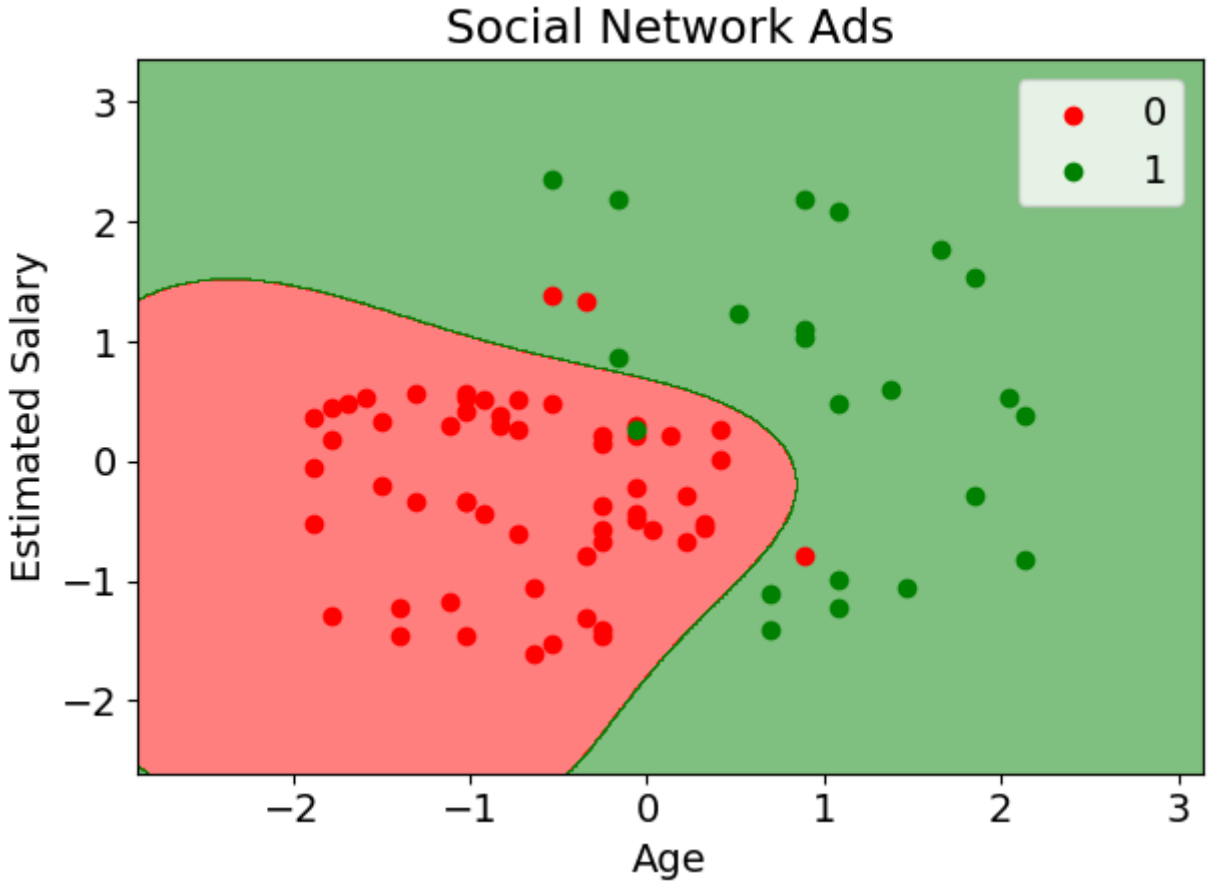

	0	1
0	55	3
1	1	21

Kiểm tra kết quả trên tập test

– Xây dựng hàm so sánh kết quả trên một điểm dữ liệu trong tập test.

```
45.def compare(i_example):
46.     x = X_test[i_example : i_example + 1]
47.     y = Y_test[i_example]
48.     y_pred = classifier.predict(x)
49.     x_inv = SC.inverse_transform(x)
50.     print(x_inv, y, y_pred)
```

Kiểm tra kết quả trên tập test

– Gọi thực hiện hàm so sánh trên 5 điểm dữ liệu, có chỉ mục từ thứ 7 đến 11 trong tập kiểm thử.

```
51.for i in range(7, 12):
52.     compare(i)
```

Kiểm tra kết quả trên tập test

Age	Estimated Salary	Purchased	Predicted Purchased
36	144,000	1	1
18	68,000	0	0
47	43,000	0	1
30	49,000	0	0
28	53,000	0	0

Chúc các bạn học tốt

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN TP.HCM

Nhóm UIT-Together

Nguyễn Tấn Trần Minh Khang